ĐẠI HỌC KINH TẾ TP.HỒ CHÍ MINH

TRƯỜNG CÔNG NGHỆ THIẾT KẾ

KHOA CÔNG NGHỆ THÔNG TIN KINH DOANH

ĐỒ ÁN MÔN HỌC

Đề tài: Phân cụm văn bản các chủ đề về thị trường lao động Việt Nam

Môn học: Xử lý ngôn ngữ tự nhiên
Mã học phần: 25C1INF50907602
Giảng viên hướng dẫn: TS. Đặng Ngọc Hoàng Thành
Nhóm sinh viên thực hiện:

Huỳnh Thụy Mai Nguyên - 31231020894
Nguyễn Đỗ Nhật Minh - 31231020749
Dương Phương Anh - 31231021067
Nguyên Lợi Thanh Dũng - 312310211226

MỤC LỤC

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI.....4
1.1. Lý do chọn đề tài.....4
1.2. Mục tiêu nghiên cứu.....4
1.3. Phương pháp nghiên cứu và thực hiện.....5
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....6
2.1. Tổng quan về Xử lý ngôn ngữ tự nhiên.....6
2.2. Bài toán Mô hình hóa chủ đề (Topic Modeling).....6
2.3. Các thuật toán mô hình hóa chủ đề.....7
2.3.1. Latent Semantic Analysis (LSA).....7
2.3.2. Latent Dirichlet Allocation (LDA).....8
2.3.3. Non-negative Matrix Factorization (NMF).....9
2.3.4. BERTopic.....10
CHƯƠNG 3: TỔNG QUAN BỘ DỮ LIỆU.....11
3.1. Mô tả bộ dữ liệu.....11
3.2. Sự phù hợp của bộ dữ liệu đối với bài toán mô hình hóa chủ đề.....11
3.3. Thu thập dữ liệu.....11
3.4. Tiền xử lý dữ liệu.....12
3.4.1. Thực hiện dịch tương đối trên dữ liệu.....12
3.4.2. Loại bỏ dữ liệu ít đáng giá.....13
3.4.3. Xử lý ở cấp độ từ.....13
3.3.4. EDA (Thăm dò dữ liệu).....14
Hình 3.2. Biểu đồ histogram hiển thị số lượng từ trên văn bản.....14
Hình 3.3. Biểu đồ histogram hiển thị số lượng token trên văn bản.....15
Hình 3.4. Biểu đồ thanh ngang hiển thị top 20 tokens xuất hiện nhiều nhất... 15
Hình 3.5. Biểu đồ Word Cloud các tokens xuất hiện sau khi tiền xử lý..... 16
CHƯƠNG 4: XÂY DỰNG MÔ HÌNH.....17
4.1. Mô hình LSA.....17
4.1.1. Chọn số cụm phù hợp.....17
4.1.2. Chạy mô hình LSA với số chủ đề là 5.....18
4.1.3. Sinh caption cho mỗi chủ đề.....19
4.2. Mô hình LDA.....20
4.2.1. Chọn số cụm phù hợp.....20
Hình 4.5. Kết quả so sánh để lựa chọn số chủ đề cho thuật toán LDA.....20
4.2.2. Kết quả phân cụm.....21
4.3. Mô hình NMF.....22
4.3.1. Chọn số cụm phù hợp.....22

4.3.2. Kết quả phân cụm.....22
4.3.3. Sinh caption cho mỗi chủ đề.....23
4.4. Mô hình BERTopic.....24
4.4.1. Chọn số cụm phù hợp.....24
4.4.2. Kết quả phân cụm.....25
Hình 4.7. Topic -1 của mô hình BERTopic.....27
Hình 4.8. Topic 0 của mô hình BERTopic.....27
Hình 4.9. Topic 1 của mô hình BERTopic.....28
Hình 4.10. Topic 3 của mô hình BERTopic.....28
Hình 4.11. Topic 2 & 4 của mô hình BERTopic.....28
CHƯƠNG 5: ĐÁNH GIÁ VÀ SO SÁNH.....29
5.1. So sánh các mô hình truyền thống - LDA, LSA, NMF.....29
5.1.1. Đánh giá dựa trên Chỉ số Định lượng.....29
5.1.2. Đánh giá dựa trên Phân phối và Ngữ nghĩa.....30
5.1.2.1. LSA.....30
5.1.2.2. LDA.....30
5.1.2.3. NMF.....31
5.1.3. Kết luận lựa chọn mô hình.....31
5.2. So sánh với mô hình Deep-Learning BERTopic.....31
5.2.1. Tổng quan các chỉ số so sánh.....31
5.2.2. So sánh về cơ chế và cách thức hoạt động.....32
5.2.2.1. Chiến lược xử lý nhiễu.....32
5.2.2.2 Không gian biểu diễn: Từ khóa và Ngữ cảnh.....33
5.2.3. So sánh khả năng phát hiện chủ đề (Topic Discovery).....33
5.2.4. Kết luận.....34
CHƯƠNG 6: KẾT LUẬN.....35
6.1. Các kết quả đạt được.....35
6.2. Hạn chế.....35
TÀI LIỆU THAM KHẢO.....37
PHỤ LỤC.....38
1. Mã nguồn dự án.....38
2. Phân công công việc.....38

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI

1.1. Lý do chọn đề tài

Trong bối cảnh hiện nay, các nền tảng mạng xã hội và trang web đã trở thành nơi tập trung khối lượng lớn văn bản phản ánh đời sống xã hội, đặc biệt là các nội dung liên quan đến việc làm và môi trường công sở. Những bài viết, chia sẻ và thảo luận này không chỉ mang tính thời sự mà còn phản ánh quan điểm và mối quan tâm của người lao động. Tuy nhiên, do dữ liệu tồn tại dưới dạng văn bản phi cấu trúc với quy mô lớn, việc khai thác thông tin một cách thủ công là không khả thi.

Mô hình hóa chủ đề là một hướng tiếp cận quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên, cho phép khám phá các chủ đề tiềm ẩn trong tập văn bản mà không cần gán nhãn trước. Thông qua các mô hình thống kê và học máy, mô hình hóa chủ đề giúp tự động nhóm các văn bản theo nội dung ngữ nghĩa, từ đó hỗ trợ phân tích xu hướng, hành vi và mối quan tâm của người dùng. Việc áp dụng mô hình hóa chủ đề cho các bài viết liên quan đến đời sống công sở không chỉ có ý nghĩa về mặt học thuật mà còn mang giá trị thực tiễn cao, khi có thể hỗ trợ các nhà nghiên cứu hiểu rõ hơn về các vấn đề nổi bật trong môi trường làm việc.

Xuất phát từ những lý do trên, đề tài được lựa chọn nhằm nghiên cứu, triển khai và so sánh các phương pháp mô hình hóa dữ liệu trên tập dữ liệu được thu thập từ các bài viết liên quan đến môi trường làm việc trên các nền tảng mạng xã hội và trang web.

1.2. Mục tiêu nghiên cứu

Mục tiêu của đề tài là nghiên cứu và áp dụng các phương pháp mô hình hóa chủ đề nhằm khám phá các chủ đề tiềm ẩn trong tập dữ liệu thu thập được. Thông qua việc xử lý và phân tích dữ liệu văn bản thực tế, đề tài hướng đến việc làm rõ cấu trúc chủ đề và các xu hướng nội dung nổi bật trong tập dữ liệu.

Bên cạnh đó, đề tài triển khai và so sánh nhiều thuật toán khác nhau nhằm đánh giá sự khác biệt về khả năng trích xuất chủ đề và tính dễ diễn giải của kết quả. Việc so sánh này giúp làm rõ ưu điểm và hạn chế của từng mô hình khi áp dụng cho dữ liệu văn bản tiếng Việt.

Ngoài ra, đề tài hướng tới việc rút ra các insight có ý nghĩa, qua đó phản ánh những mối quan tâm, vấn đề phổ biến và xu hướng thảo luận liên quan đến môi trường làm việc. Các kết quả này không chỉ góp phần củng cố kiến thức lý thuyết về xử lý ngôn ngữ tự nhiên mà còn minh họa khả năng ứng dụng của việc mô hình hóa chủ đề trong phân tích dữ liệu văn bản, phục vụ cho nghiên cứu và thực tiễn.

1.3. Phương pháp nghiên cứu và thực hiện

Để nghiên cứu và thực hiện đề tài, nhóm sử dụng những phương pháp sau:

Mục đích	Phương pháp
Thu thập dữ liệu	Cào dữ liệu (data crawling) từ mạng xã hội Threads, Facebook, diễn đàn Thu thập thủ công
Tiền xử lý dữ liệu	Dịch những từ tiếng Anh đan xen, loại bỏ stopwords, chuẩn hóa ký tự, chính tả, tokenization, loại spam/duplicate
Khám phá & chuẩn bị dữ liệu	Phân tích tần suất từ, word cloud, phân phối độ dài câu, phân tích cụm từ phổ biến (n-gram)
Mô hình hoá chủ đề	- LDA (Latent Dirichlet Allocation), - LSA (Latent Semantic Analysis) - NMF (Non-negative Matrix Factorization) - BERTopic
Đánh giá & diễn giải chủ đề	- Compactness - Separation - Sinh caption Chọn ra mô hình tốt nhất
Phân tích nội dung & đánh giá insights	- Thống kê tỷ trọng chủ đề - Đúc kết ra ý nghĩa chủ đề

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về Xử lý ngôn ngữ tự nhiên

Xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP) là một lĩnh vực quan trọng của trí tuệ nhân tạo (Artificial Intelligence – AI), tập trung vào việc giúp máy tính hiểu, phân tích và tạo ra ngôn ngữ của con người. NLP kết hợp kiến thức từ khoa học máy tính, ngôn ngữ học và học máy để xử lý các dạng dữ liệu văn bản và lời nói. Nhờ vậy, máy tính có thể thực hiện các nhiệm vụ như phân tích cú pháp câu, nhận dạng thực thể, phân loại văn bản, dịch ngôn ngữ hay trả lời câu hỏi, qua đó thu hẹp khoảng cách giao tiếp giữa con người và máy móc.

Ứng dụng của NLP rất đa dạng. Trong thực tế, NLP được dùng để xây dựng chatbot và trợ lý ảo, giúp tự động hóa chăm sóc khách hàng. Ngoài ra, NLP còn được ứng dụng trong dịch máy, tìm kiếm thông tin, phân tích ý kiến khách hàng, hỗ trợ tuyển dụng, y tế và giáo dục, góp phần nâng cao hiệu quả xử lý và khai thác dữ liệu ngôn ngữ ở quy mô lớn.

2.2. Bài toán Mô hình hóa chủ đề (Topic Modeling)

Mô hình hóa chủ đề là một bài toán trong lĩnh vực xử lý ngôn ngữ tự nhiên nhằm tự động khám phá các chủ đề tiềm ẩn trong một tập hợp lớn các văn bản. Thay vì đọc và phân loại thủ công, mô hình hóa chủ đề giúp máy tính nhận diện những nhóm nội dung có ý nghĩa dựa trên sự xuất hiện và đồng thời xuất hiện của các từ. Mỗi chủ đề thường được biểu diễn bằng một tập các từ khóa có xác suất cao, phản ánh nội dung cốt lõi mà chủ đề đó đề cập.

Mô hình hóa chủ đề về bản chất xem mỗi tài liệu riêng lẻ trong một tập văn bản như một mô hình bag of words. Điều này có nghĩa là thuật toán bỏ qua thứ tự từ và ngữ cảnh, chỉ tập trung vào tần suất xuất hiện của các từ, cũng như mức độ các từ cùng xuất hiện với nhau trong từng tài liệu.

Hầu hết các phương pháp mô hình hóa chủ đề bắt đầu bằng việc tạo ra một ma trận tài liệu–thuật ngữ. Ma trận này biểu diễn tập dữ liệu văn bản với các tài liệu là các hàng và các từ riêng lẻ là các cột (hoặc ngược lại). Các giá trị trong ma trận cho biết tần suất một từ cụ thể xuất hiện trong mỗi tài liệu. Ma trận này sau đó được sử dụng để tạo ra một không gian vector, trong đó n từ tương ứng với n chiều. Giá trị của mỗi hàng thể hiện vị trí của tài liệu đó trong không gian vector. Những tài liệu sử dụng các nhóm từ tương tự và với tần suất gần nhau sẽ nằm gần nhau hơn trong không gian vector. Từ đó, các mô hình mô hình hóa chủ đề xem sự gần nhau trong không gian vector là dấu hiệu cho thấy các tài liệu chia sẻ nội dung hoặc chủ đề khái niệm tương tự nhau.

2.3. Các thuật toán mô hình hóa chủ đề

2.3.1. Latent Semantic Analysis (LSA)

LSA là một trong những kỹ thuật nền tảng trong bài toán mô hình hóa chủ đề. Ý tưởng cốt lõi của LSA là lấy một ma trận biểu diễn các tài liệu và các thuật ngữ, rồi phân rã nó thành hai ma trận riêng biệt: ma trận tài liệu–chủ đề và ma trận chủ đề–thuật ngữ.

Bước đầu tiên là tạo ma trận tài liệu–thuật ngữ. Với m tài liệu và n từ trong tập từ vựng, ta có thể xây dựng một ma trận m × n ký hiệu là A, trong đó mỗi hàng đại diện cho một tài liệu và mỗi cột đại diện cho một từ. Ở phiên bản đơn giản nhất của LSA, mỗi phần tử trong ma trận chỉ đơn thuần là số lần từ thứ j xuất hiện trong tài liệu thứ i. Tuy nhiên, trên thực tế, việc dùng tần suất thô thường không mang lại hiệu quả tốt vì nó không phản ánh được mức độ quan trọng của từng từ trong tài liệu.

Vậy nên, LSA thường thay thế tần suất thô trong ma trận tài liệu–thuật ngữ bằng điểm TF-IDF. TF-IDF gán một trọng số cho thuật ngữ j trong tài liệu i như sau:

$$w_{i,j} = tf_{i,j} \times \log\left(\frac{N}{df_i}\right)$$

- $w_{i,j}$: điểm TF-IDF của từ j trong tài liệu i
- $tf_{i,j}$: số lần từ j xuất hiện trong tài liệu i
- N : tổng số tài liệu trong toàn bộ tập dữ liệu (corpus)
- df_i: số tài liệu có chứa từ j

Về mặt trực giác, một thuật ngữ sẽ có trọng số lớn khi nó xuất hiện thường xuyên trong tài liệu nhưng lại hiếm xuất hiện trong toàn bộ tập văn bản. Một từ có thể xuất hiện nhiều lần trong một tài liệu, nhưng do nó khá phổ biến trong toàn bộ corpus nên điểm TF-IDF sẽ không cao, và ngược lại.

Khi đã có ma trận tài liệu–thuật ngữ A, ta bắt đầu suy nghĩ về các chủ đề tiềm ẩn. Trên thực tế, A thường rất thưa, nhiều nhiễu và dư thừa trên nhiều chiều. Do đó, để tìm ra một số ít các chủ đề tiềm ẩn có khả năng nắm bắt mối quan hệ giữa từ và tài liệu, ta cần thực hiện giảm chiều dữ liệu cho A.

Việc giảm chiều này có thể được thực hiện bằng SVD rút gọn (truncated SVD). SVD (Singular Value Decomposition) là một kỹ thuật trong đại số tuyến tính, dùng để phân tích một ma trận bất kì M thành tích của ba ma trận nhỏ hơn:

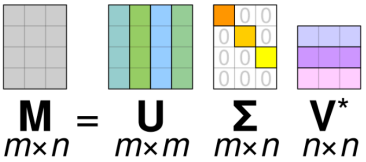

Trong đó S là ma trận đường chéo chứa các giá trị suy biến của M. Điểm quan trọng là truncated SVD giúp giảm chiều bằng cách chỉ giữ lại t giá trị suy biến lớn nhất, đồng thời chỉ giữ t cột đầu tiên của U và V. Trong trường hợp này, t là một siêu tham số có thể lựa chọn với t là số chủ đề mà ta mong muốn.

2.3.2. Latent Dirichlet Allocation (LDA)

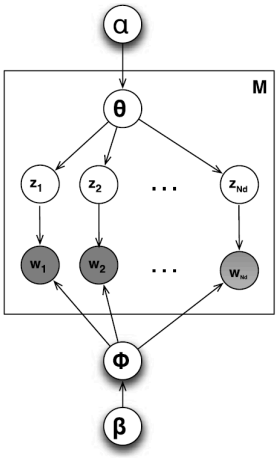

Hình 2.1. Minh họa cách hoạt động của mô hình LDA

(Nguồn: towardsdatascience.com)

Mô hình LDA được đề xuất bởi Blei và cộng sự (2003), là một mô hình mô hình hóa chủ đề dựa trên phương pháp Bayes, mở rộng từ pLSA bằng cách đưa các phân phối tiên nghiệm Dirichlet vào quá trình ước lượng. Trong LDA, mỗi tài liệu được mô hình hóa như một hỗn hợp xác suất của các chủ đề tiềm ẩn, trong khi mỗi chủ đề được biểu diễn bằng một phân phối xác suất trên tập từ vựng.

Xét ví dụ một tờ báo với ba mục: chính trị, thể thao và văn hóa – mỗi mục tương đương với một chủ đề. Phân phối tỷ lệ của các chủ đề trong từng bài viết của tờ báo là một ví dụ điển hình của phân phối Dirichlet:

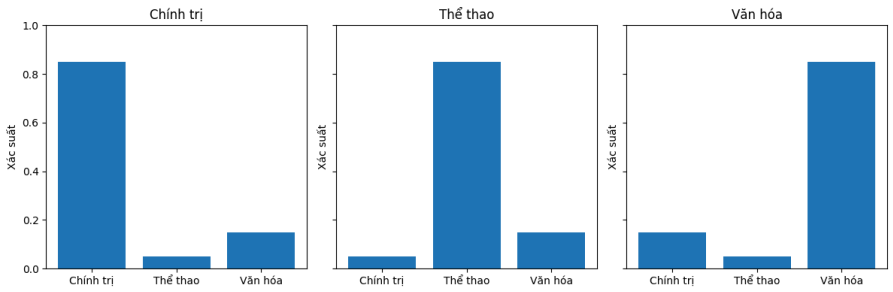

Hình 2.2. Minh họa phân phối Dirichlet trong mô hình LDA

LDA giả định rằng phân phối chủ đề của mỗi tài liệu được lấy mẫu từ phân phối Dirichlet với tham số α, còn phân phối từ vựng của mỗi chủ đề được lấy mẫu từ phân phối Dirichlet với tham số β. Với mỗi từ trong tài liệu, mô hình lần lượt chọn một chủ đề dựa trên phân phối chủ đề của tài liệu, sau đó sinh ra từ tương ứng dựa trên phân phối từ vựng của chủ đề đã chọn. Mặc dù không trực tiếp sinh văn bản, LDA sử dụng giả định này để suy ngược lại các phân phối chủ đề và từ vựng tiềm ẩn trong tập dữ liệu.

Do phân phối hậu nghiệm của các biến ẩn không thể tính toán chính xác, LDA sử dụng các phương pháp suy luận xấp xỉ để ước lượng mô hình. Kết quả thu được bao gồm phân phối tài liệu–chủ đề và phân phối chủ đề–từ, cho phép diễn giải các chủ đề thông qua các từ có xác suất cao và gán xác suất chủ đề cho từng tài liệu. Nhờ khung xác suất đầy đủ, LDA có khả năng khái quát hóa sang các tài liệu mới, đồng thời cung cấp nền tảng linh hoạt cho việc mở rộng và tích hợp vào các mô hình phức tạp hơn.

2.3.3. Non-negative Matrix Factorization (NMF)

Mô hình Phân tích ma trận không âm (Non-negative Matrix Factorization – NMF), được giới thiệu bởi Lee và cộng sự (1999), là một nâng cấp của mô hình LSA.

Mô hình NMF dựa trên ý tưởng cơ bản của mô hình LSA. NMF phân rã ma trận tài liệu-từ vựng thành một ma trận chủ đề-tài liệu U và một ma trận chủ đề-từ vựng V^T, tương tự như SVD, nhưng với ràng buộc bổ sung là U và V^T chỉ chứa các phần tử không âm.

NMF vượt trội hơn LSA vì các chủ đề trong NMF được hình thành từ sự kết hợp cộng của các từ, giúp con người dễ hiểu ý nghĩa chủ đề hơn, trong khi LSA (dựa trên SVD) cho phép giá trị âm khiến việc diễn giải trở nên khó khăn. Ngoài ra, NMF thường tạo ra các chủ đề rõ ràng, tách biệt hơn trong bài toán khai thác văn bản và phù hợp tự nhiên với dữ liệu tần suất như ma trận tài liệu-từ vựng hoặc TF-IDF, vốn chỉ chứa các giá trị không âm.

2.3.4. BERTopic

BERTopic là một mô hình hiện đại được đề xuất bởi Grootendorst (2022). Mô hình này khắc phục các hạn chế của các phương pháp truyền thống như LDA, đặc biệt trong việc nắm bắt ngữ nghĩa và xử lý văn bản ngắn, bằng cách tiếp cận bài toán theo hướng nhóm các tài liệu có nội dung ngữ nghĩa tương đồng, từ đó suy ra các chủ đề tiềm ẩn.

Trước hết, mỗi tài liệu trong tập dữ liệu được chuyển đổi thành một vector ngữ nghĩa (embedding). Các embedding này biểu diễn ý nghĩa ngữ cảnh của toàn bộ văn bản trong không gian vector nhiều chiều, cho phép đo lường mức độ tương đồng ngữ nghĩa giữa các tài liệu thông qua các độ đo khoảng cách. Nhờ đó, những văn bản có nội dung tương tự sẽ nằm gần nhau trong không gian biểu diễn.

Do các embedding thường có số chiều cao, BERTopic áp dụng bước giảm chiều dữ liệu bằng cách sử dụng UMAP (Uniform Manifold Approximation and Projection) để chiếu các embedding từ không gian chiều cao xuống không gian chiều thấp hơn. Việc giảm chiều giúp làm nổi bật các vùng tập trung của dữ liệu và tạo điều kiện thuận lợi cho quá trình phân cụm.

Trên không gian embedding đã được giảm chiều, BERTopic tiến hành phân cụm các tài liệu để hình thành các chủ đề. Thuật toán HDBSCAN thường được sử dụng do khả năng tự động xác định số lượng cụm và xử lý nhiễu bằng cách gán các tài liệu không phù hợp vào nhóm ngoại lai. Mỗi cụm tài liệu thu được tương ứng với một chủ đề tiềm ẩn, trong đó các văn bản trong cùng một cụm có mức độ tương đồng ngữ nghĩa cao.

Sau khi xác định các cụm tài liệu, BERTopic xây dựng biểu diễn chủ đề thông qua việc trích xuất các từ khóa đặc trưng. Trước tiên, các phương pháp vector hóa như CountVectorizer được sử dụng để lọc và chọn ra các từ hoặc cụm từ có giá trị phân biệt. Tiếp theo, mô hình áp dụng class-based TF-IDF, trong đó toàn bộ các tài liệu thuộc cùng một chủ đề được gộp lại để tính trọng số từ vựng. Cách tiếp cận này giúp làm nổi bật các từ quan trọng cho từng chủ đề và giảm ảnh hưởng của các từ xuất hiện phổ biến trên nhiều chủ đề khác nhau.

Cuối cùng, BERTopic có thể sử dụng các mô hình biểu diễn chủ đề dựa trên ngữ nghĩa nhằm tinh chỉnh danh sách từ khóa đại diện. Các phương pháp này khai thác mối quan hệ giữa embedding của tài liệu và embedding của từ vựng để lựa chọn các từ khóa vừa mang tính đặc trưng cao, vừa hạn chế sự trùng lặp về ngữ nghĩa. Nhờ sự kết hợp giữa biểu diễn ngữ nghĩa, phân cụm và tái biểu diễn chủ đề, BERTopic tạo ra các chủ đề có tính diễn giải tốt và phù hợp với các tập dữ liệu văn bản hiện đại.

CHƯƠNG 3: TỔNG QUAN BỘ DỮ LIỆU

3.1. Mô tả bộ dữ liệu

Bộ dữ liệu được xây dựng từ các bài viết công khai thu thập trên các nền tảng mạng xã hội và trang web, bao gồm Threads, Facebook và trang nền tảng thông tin doanh nghiệp 1900.com.vn. Đây là những nền tảng phổ biến đối với người trẻ Việt Nam, đặc biệt là nhóm người lao động và sinh viên mới ra trường – đối tượng thường xuyên chia sẻ quan điểm, trải nghiệm và cảm xúc liên quan đến công việc, môi trường văn phòng và đời sống công sở.

3.2. Sự phù hợp của bộ dữ liệu đối với bài toán mô hình hóa chủ đề

Topic Modeling là một phương pháp học không giám sát nhằm khám phá các chủ đề tiềm ẩn trong tập văn bản lớn dựa trên sự đồng xuất hiện của từ ngữ. Do đó, chất lượng và đặc điểm của bộ dữ liệu đầu vào đóng vai trò quyết định đến khả năng trích xuất chủ đề có ý nghĩa của mô hình.

Trước hết, bộ dữ liệu bao gồm những bài viết, chia sẻ có độ dài từ trung bình trở lên. Đây là độ dài phù hợp cho dữ liệu đầu vào của bài toán mô hình hóa chủ đề. Hơn nữa, các văn bản có đủ ngữ cảnh giới hạn trong một bối cảnh cụ thể giúp mô hình học được các mối quan hệ ngữ nghĩa để hình thành các chủ đề ổn định. Bên cạnh điểm mạnh về thuật toán, nội dung dữ liệu tập trung vào các chủ đề xoay quanh việc làm và văn hóa công sở, chẳng hạn như trải nghiệm đi làm, quá trình phỏng vấn và các vấn đề thường gặp tại nơi làm việc. Ví dụ, trên nền tảng Threads, các bài viết được thu thập thông qua các chủ đề tiêu biểu như "đi làm có gì vui", "văn phòng GenZ", "phỏng vấn", v.v. Việc lựa chọn các chủ đề này nhằm đảm bảo rằng dữ liệu phản ánh đúng các mối quan tâm và diễn ngôn phổ biến của người lao động trẻ trong bối cảnh hiện nay làm giàu tính ngữ nghĩa cho mô hình.

3.3. Thu thập dữ liệu

Bộ dữ liệu được thu thập bằng phương pháp cào dữ liệu, sử dụng thư viện Selenium nhằm tự động hóa thao tác trình duyệt và thu thập nội dung động. Thư viện này cho phép mô phỏng hành vi người dùng như nhấp chuột, nhập từ khóa tìm kiếm và cuộn trang để tải thêm nội dung.

Quy trình cào dữ liệu được thực hiện theo các bước chính:

(1) Truy cập chức năng tìm kiếm.

(2) Nhập từ khóa tương ứng với từng chủ đề.

(3) Lựa chọn kết quả phù hợp.

(4) Thu thập nội dung các bài viết hiển thị trên trang.

Để đảm bảo thu thập được nhiều bài viết, chương trình thực hiện cuộn trang nhiều lần, mỗi lần thu thập các bài viết mới được tải. Sau khi thu thập dữ liệu thành công, các bài viết được tổng hợp vào một DataFrame để thuận tiện cho các bước xử lý tiếp theo.

3.4. Tiền xử lý dữ liệu

Sau khi có được dữ liệu văn bản, nhóm tiến hành trực quan hoá các từ ngữ được sử dụng nhiều nhất bằng biểu đồ Word Cloud.

Hình 3.1. Biểu đồ Word Cloud sau khi thu thập dữ liệu

Quan sát biểu đồ, nhóm nhận thấy có rất nhiều từ gây nhiễu, từ tiếng anh và từ ít đáng giá đối với chủ đề thị trường lao động. Do đó nhóm tiến hành xử lý thật cẩn thận và chi tiết các yếu tố gây nhiễu để đưa ra kết quả tối ưu ở các mục tiếp theo.

3.4.1. Thực hiện dịch tương đối trên dữ liệu

Bước đầu tiên nhóm sẽ tự động dịch các cụm từ tiếng Anh trong văn bản sang tiếng Việt trong toàn bộ dữ liệu thu thập, đồng thời bảo vệ các thuật ngữ chuyên môn được định nghĩa sẵn.

- Bảo vệ thuật ngữ: Hàm protect_phrase() "khóa" các cụm từ trong whitelist (ví dụ: business analyst, frontend, marketing) - không dịch nghĩa tiếng Việt của những từ này để giữ trọn vẹn đặc trưng dữ liệu văn bản từ mạng xã hội cũng

như đặc trưng tên gọi các vị trí trong bối cảnh thực tế, bằng cách thay thế khoảng trắng bằng dấu gạch dưới.

- Dịch hàng loạt: Hàm chính translate_word() sử dụng GoogleTranslator để dịch các văn bản đầu vào. Chỉ các văn bản chứa tiếng Anh mới được dịch, các văn bản khác được giữ nguyên.
- Đầu ra: Danh sách văn bản đã được chuẩn hóa, chủ yếu bằng tiếng Việt với các thuật ngữ chuyên ngành quan trọng được giữ nguyên gốc.

3.4.2. Loại bỏ dữ liệu ít đáng giá

Trước hết, các bài viết có độ dài quá ngắn được loại bỏ do không cung cấp đủ thông tin ngữ nghĩa cần thiết cho việc hình thành và phân biệt các chủ đề. Ngược lại, những bài viết có độ dài quá lớn thường chứa nhiều nội dung lan man, không tập trung, dễ gây nhiễu cho quá trình mô hình hóa. Cụ thể, các bài viết có số lượng từ nhỏ hơn 12 hoặc lớn hơn 1500 không được đưa vào tập dữ liệu cuối cùng.

Tiếp theo, các bài viết mang tính chất spam hoặc seeding được tiến hành lọc bỏ. Nhóm nội dung này chủ yếu liên quan đến quảng cáo, tuyển cộng tác viên, hoa hồng, lãi suất hoặc các thông tin mang tính thương mại, không phản ánh trải nghiệm thực tế của người lao động văn phòng. Việc loại bỏ các bài viết này nhằm đảm bảo rằng mô hình topic modelling tập trung vào các chủ đề xã hội, nghề nghiệp và đời sống công sở, thay vì các nội dung không liên quan đến mục tiêu nghiên cứu.

Ngoài ra, vấn đề trùng lặp dữ liệu cũng được xem xét và xử lý. Trong quá trình thu thập, cùng một bài viết có thể xuất hiện dưới nhiều chủ đề khác nhau do trùng lặp từ khóa tìm kiếm hoặc cách phân loại nội dung của nền tảng. Các bài viết có nội dung hoàn toàn giống nhau được giữ lại một lần duy nhất nhằm tránh làm sai lệch phân bố dữ liệu, cũng như hạn chế ảnh hưởng tiêu cực đến kết quả phân cụm và cho ra chủ đề của mô hình.

Thông qua các bước tiền xử lý trên, bộ dữ liệu sau cùng đạt được mức độ sạch, nhất quán và phù hợp hơn cho bài toán khai phá chủ đề, tạo nền tảng vững chắc cho việc áp dụng và so sánh các mô hình topic modelling trong các chương tiếp theo.

3.4.3. Xử lý ở cấp độ từ

Hàm deep_preprocess() thực hiện làm sạch và chuẩn hóa văn bản tiếng Việt thô (từ mạng xã hội, bài viết) thành dạng phù hợp cho các mô hình NLP.

- Chuẩn hóa & Thay thế: Chuyển văn bản về chữ thường và thay thế các từ teencode phổ biến (dựa trên teencode_dict) về dạng chuẩn.
- Loại bỏ thành phần phi văn bản: Xóa các liên kết (URL), credit/nguồn trích dẫn, emoji, hashtag và các mention (tag người dùng) khỏi văn bản.

- Chuẩn hóa từ: Rút gọn các từ bị kéo dài (ví dụ: "thích quáaaaa" thành "thích quá") và loại bỏ ký tự đặc biệt.
- Tách từ & Lọc: Sử dụng ViTokenizer để tách từ tiếng Việt chính xác, sau đó loại bỏ các từ dừng (vietnamese_stopwords) và từ quá ngắn.
- Đầu ra: Tạo hai cột dữ liệu mới:
    - tokens: Danh sách các từ đã được làm sạch, dùng cho các mô hình như LDA.
    - clean_text: Chuỗi văn bản sạch thu được bằng cách nối các tokens, dùng cho các mô hình như BERTopic. Các dòng trống sau khi xử lý đã được loại bỏ.

3.3.4. EDA (Thăm dò dữ liệu)

Để nắm được độ dài của từng văn bản, nhóm thống kê và trực quan hoá số lượng từ, token trên văn bản.

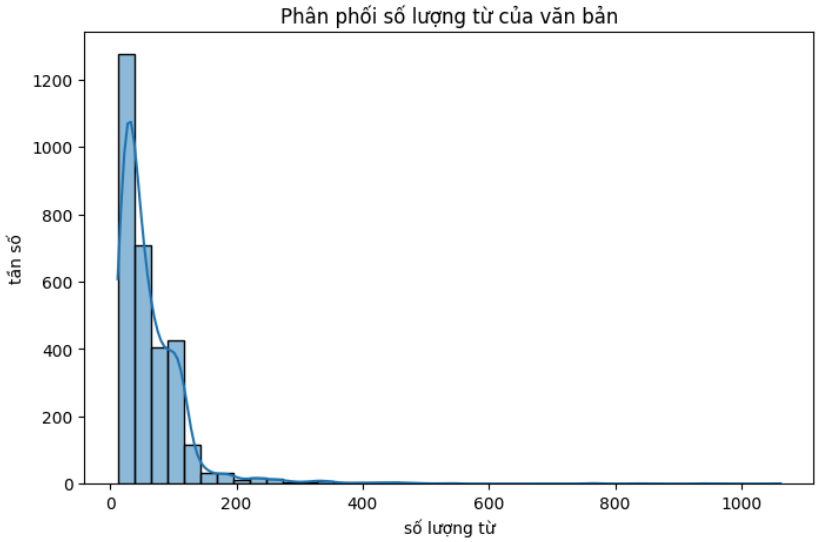

Hình 3.2. Biểu đồ histogram hiển thị số lượng từ trên văn bản

Quan sát histogram cho thấy đa số bài dưới 100 từ, phân phối lệch phải mạnh, tuy nhiên vẫn còn một số bài rất dài (trên 500 từ). Điều này phản ánh đặc điểm chung của các bài viết trên mạng xã hội là ngắn gọn, súc tích, đi thẳng vào chủ đề chính.

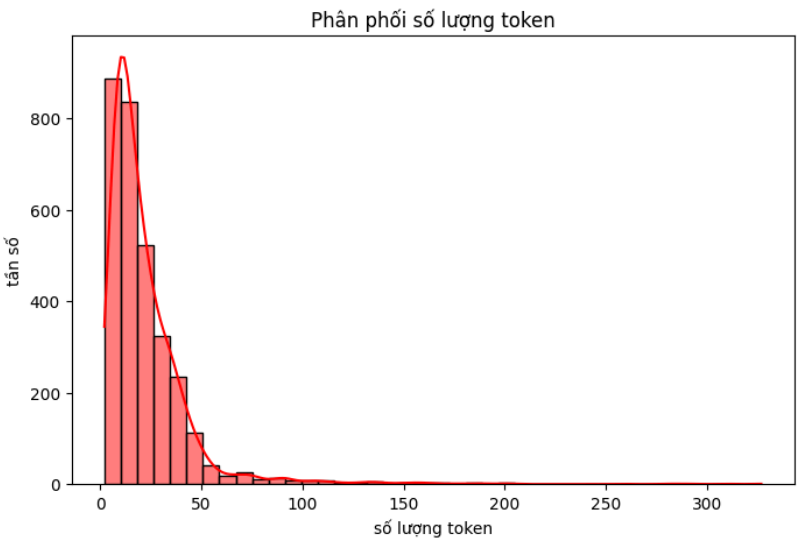

Hình 3.3. Biểu đồ histogram hiển thị số lượng token trên văn bản

Sau khi chuẩn hóa, tokenize, lọc stopwords, loại những từ ít đáng giá đã giúp văn bản ngắn lại đáng kể. Từ biểu đồ phân phối token cho thấy phần lớn review chỉ còn 10–50 token nghĩa là noise giảm đáng kể và giúp cho mô hình topic sẽ dễ bắt cấu trúc hơn. Điều này chứng minh pipeline xử lý text hoạt động ổn: giữ thông tin, cắt bỏ nhiễu.

Từ kết quả sau tokenize, nhóm vẽ biểu đồ các token xuất hiện nhiều nhất.

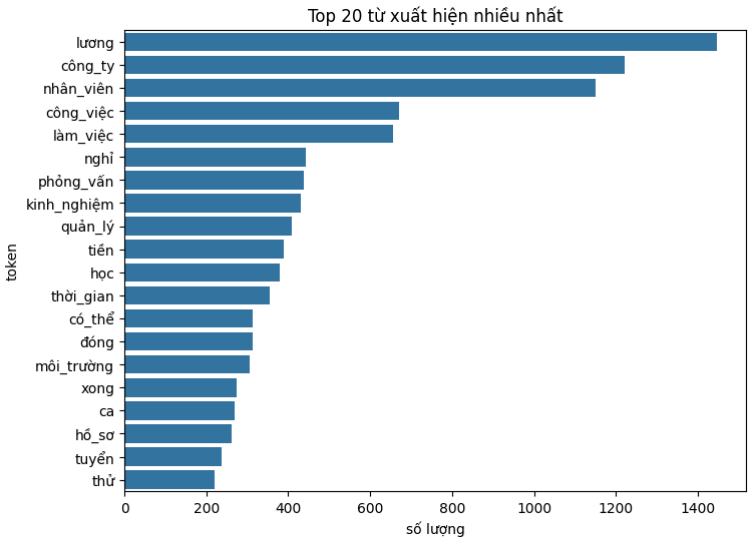

Hình 3.4. Biểu đồ thanh ngang hiển thị top 20 tokens xuất hiện nhiều nhất

Hình 3.5. Biểu đồ Word Cloud các tokens xuất hiện sau khi tiền xử lý

Như chủ đề về những cảm nhận xoay quanh việc làm và môi trường công sở, những từ vựng được đề cập đến nhiều nhất là lương, công ty, nhân viên, công việc, kinh nghiệm và những từ ngữ rất liên quan khác.

CHƯƠNG 4: XÂY DỰNG MÔ HÌNH

4.1. Mô hình LSA

4.1.1. Chọn số cụm phù hợp

Để lựa chọn số chủ đề phù hợp (đạt kết quả chính xác nhất), ta sẽ đánh giá theo các tham số Compactness, Separation, Score. Với **Compactness** là chỉ số đo lường độ chặt chẽ của các thành phần trong cùng một chủ đề, trong đó giá trị càng thấp thể hiện các từ ngữ và tài liệu trong một cụm càng đồng nhất và tập trung; **Separation** có ý nghĩa là thước đo khoảng cách hay sự khác biệt giữa các chủ đề với nhau, với mục tiêu là các cụm phải đủ xa nhau để tránh chồng lấn về ngữ nghĩa; và cuối cùng, **Score** được tính theo tỷ lệ giữa Separation và Compactness nhằm tìm ra điểm cân bằng tối ưu giữa sự phân tách và tính nhất quán.

```
k= 5 | Compact=0.0934 | Sep=0.6903 | Score=7.3907
k= 6 | Compact=0.1061 | Sep=0.7194 | Score=6.7785
k= 7 | Compact=0.1211 | Sep=0.7402 | Score=6.1147
k= 8 | Compact=0.1313 | Sep=0.7473 | Score=5.6938
k= 9 | Compact=0.1429 | Sep=0.7481 | Score=5.2351
k=10 | Compact=0.1566 | Sep=0.7570 | Score=4.8328
k=11 | Compact=0.1779 | Sep=0.7557 | Score=4.2473
k=12 | Compact=0.1863 | Sep=0.7579 | Score=4.0689
k=13 | Compact=0.1988 | Sep=0.7629 | Score=3.8381
k=14 | Compact=0.2078 | Sep=0.7666 | Score=3.6886
k=15 | Compact=0.2105 | Sep=0.7724 | Score=3.6701
k=16 | Compact=0.2469 | Sep=0.7539 | Score=3.0529
k=17 | Compact=0.2407 | Sep=0.7636 | Score=3.1727
k=18 | Compact=0.2532 | Sep=0.7614 | Score=3.0071
k=19 | Compact=0.2741 | Sep=0.7567 | Score=2.7607
k=20 | Compact=0.2704 | Sep=0.7695 | Score=2.8455
k=21 | Compact=0.2706 | Sep=0.7737 | Score=2.8585
k=22 | Compact=0.2796 | Sep=0.7624 | Score=2.7269
k=23 | Compact=0.2838 | Sep=0.7828 | Score=2.7588
k=24 | Compact=0.3069 | Sep=0.7788 | Score=2.5373
k=25 | Compact=0.3056 | Sep=0.7741 | Score=2.5331
```

Hình 4.1. Kết quả so sánh để lựa chọn số chủ đề

Dựa trên kết quả tính toán, số lượng chủ đề tối ưu nhất để lựa chọn là k = 5. Tại điểm này, chỉ số Score đạt giá trị cao nhất (xấp xỉ 7.4), cho thấy sự cân bằng hoàn hảo nhất giữa việc các chủ đề có nội dung tập trung, nhất quán (Compactness thấp) và có sự phân biệt rõ ràng với nhau (Separation cao). Khi số lượng topic tăng dần từ 5 lên 30, chỉ số Score có xu hướng giảm mạnh và liên tục, chứng tỏ việc tăng thêm số lượng

chủ đề không mang lại hiệu quả về mặt phân loại mà ngược lại còn làm cho các topic trở nên loãng và chồng chéo lên nhau.

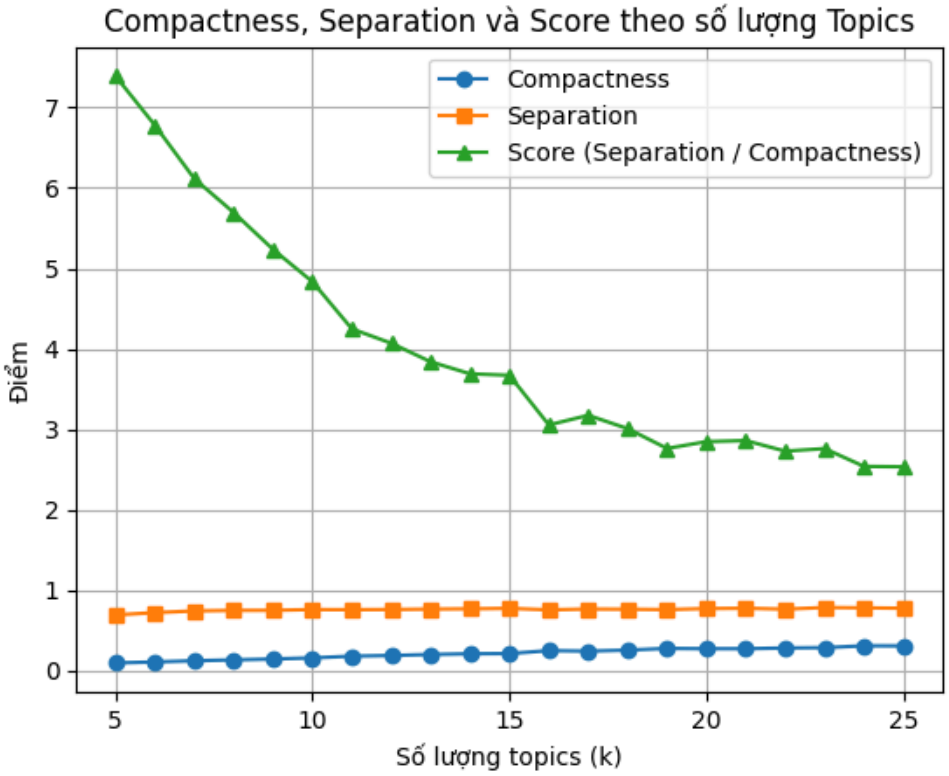

Hình 4.2. Trực quan hóa kết quả so sánh để lựa chọn số chủ đề

Nếu xét theo phương pháp "điểm khuỷu" (elbow method), điểm k = 5 chính là vị trí mang lại giá trị phân tích tốt nhất trước khi hiệu quả của mô hình bị bão hòa. Việc chọn 5 chủ đề sẽ giúp mô hình LSA giữ được độ súc tích, tránh tình trạng chia nhỏ dữ liệu quá mức khiến các chủ đề bị vụn vặt và khó giải thích về mặt ngữ nghĩa.

4.1.2. Chạy mô hình LSA với số chủ đề là 5

```
Topic 1: lương, nhân_viên, công_ty, công_việc, làm_việc, phỏng_vấn, nghỉ, đóng, kinh_nghiệm, thời_gian
Topic 2: lương, nhân_viên, tr, đóng, thưởng, hạn, nợ, trừ, tăng_ca, nghỉ
Topic 3: lương, phỏng_vấn, tr, đóng, kinh_nghiệm, hồ_sơ, thử, hạn, hr, anh_chị
Topic 4: đóng, công_ty, bảo_hiểm, bệnh, bhxh, xã_hội, bây_giờ, tự_nguyện, mọi_người, đầy_đủ
Topic 5: phỏng_vấn, nhân_viên, công_ty, câu, trả_lời, nghỉ, hr, gọi, thông_báo, xong
```

Hình 4.3. Kết quả thuật toán LSA với số chủ đề là 5

Dựa trên kết quả chạy mô hình LSA với 5 chủ đề, có thể thấy kết quả đã bắt đầu phân tách được các mảng nội dung chính trong dữ liệu, tuy nhiên vẫn còn hiện tượng giao thoa từ vựng giữa các nhóm. Các chủ đề như **Topic 4** và **Topic 5** thể hiện chất lượng rất tốt với hệ thống từ khóa mang tính đặc trưng cao và tách biệt rõ rệt về mặt ngữ nghĩa. Ngược lại, **Topic 1** và **Topic 3** vẫn còn khá chung chung, chứa nhiều

từ vựng phổ biến xuất hiện lặp lại ở nhiều nhóm khác nhau, khiến ranh giới nội dung chưa thực sự tách biệt.

Về ý nghĩa cụ thể, mỗi chủ đề có thể được đặt tên dựa trên tập hợp từ khóa đặc trưng như sau:

- **Topic 1 (Tổng quan về việc làm và tuyển dụng):** Đây là nhóm nội dung cơ bản nhất, bao quát các vấn đề chung như công ty, công việc và kinh nghiệm làm việc.
- **Topic 2 (Chế độ lương thưởng và thu nhập):** Chủ đề này có chất lượng tốt nhờ tập trung sâu vào các từ khóa cụ thể về tài chính như tiền thưởng, tăng ca, nợ và các khoản khấu trừ.
- **Topic 3 (Quy trình hồ sơ và phỏng vấn):** Nhóm này xoay quanh các thủ tục hành chính dành cho ứng viên như chuẩn bị hồ sơ, thời gian thử việc và tương tác với bộ phận nhân sự.
- **Topic 4 (Chế độ Bảo hiểm xã hội):** Đây là chủ đề xuất sắc nhất với các từ khóa chuyên biệt hoàn toàn về BHXH, bảo hiểm tự nguyện và các quyền lợi liên quan đến sức khỏe, bệnh tật.
- **Topic 5 (Thông báo và phản hồi phỏng vấn):** Chủ đề này rất rõ ràng khi tập trung vào quy trình liên lạc sau phỏng vấn, bao gồm các câu trả lời, gọi điện và thông báo kết quả từ HR.

4.1.3. Sinh caption cho mỗi chủ đề

```
Topic 1: lương | nhân_viên | công_ty | công_việc | làm_việc
Topic 2: lương | nhân_viên | tr | đóng | thưởng
Topic 3: lương | phỏng_vấn | tr | đóng | kinh_nghiệm
Topic 4: đóng | công_ty | bảo_hiểm | bệnh | bhxh
Topic 5: phỏng_vấn | nhân_viên | công_ty | nghỉ | câu
```

Hình 4.4. Caption của từng chủ đề từ mô hình LSA

Phương pháp sinh caption là tận dụng đồng thời thông tin từ mô hình LSA và ngữ cảnh thực tế của các bài viết đại diện, nhằm tạo ra nhãn chủ đề vừa mang tính khái quát vừa dễ diễn giải. Cụ thể, trước hết mô hình LSA được sử dụng để trích xuất các từ khóa có trọng số cao nhất trong vector chủ đề (components), phản ánh những thuật ngữ quan trọng về mặt toán học và cấu trúc ngữ nghĩa của topic. Sau đó, với mỗi topic, các bài viết thuộc chủ đề đó được chiếu không gian LSA và một tâm cụm (centroid) được tính toán; những bài viết có khoảng cách cosine nhỏ nhất tới tâm cụm được xem là các tài liệu tiêu biểu. Từ các tài liệu tiêu biểu này, những từ xuất hiện thường xuyên nhất được trích xuất để đại diện cho ngôn ngữ sử dụng thực tế của topic. Cuối cùng, hai tập từ khóa này được gộp lại, loại bỏ trùng lặp và nối thành một

caption ngắn gọn, giúp mô tả chủ đề theo cách vừa phản ánh bản chất thống kê của mô hình, vừa bám sát nội dung thực của dữ liệu văn bản.

Nhận xét về caption được dự đoán ở phần 4.1.2 và caption được sinh ra ở phần 4.1.3: Kết quả so sánh giữa các caption dự đoán và danh sách từ khóa đại diện được sinh ra bởi thuật toán cho thấy một sự tương quan cao. Vậy, hàm sinh caption đã phản ánh đúng cấu trúc dữ liệu, các nhãn chủ đề đưa ra là hoàn toàn hợp lý và có cơ sở dữ liệu xác thực.

4.2. Mô hình LDA

4.2.1. Chọn số cụm phù hợp

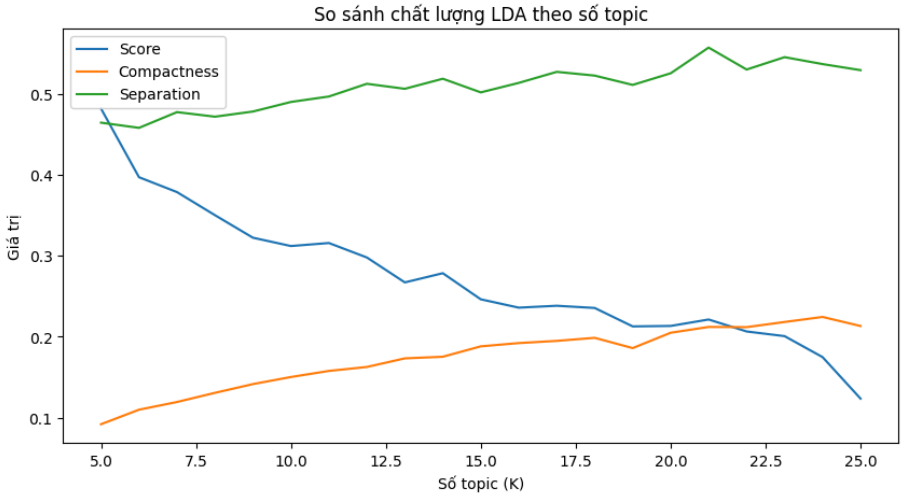

Hình 4.5. Kết quả so sánh để lựa chọn số chủ đề cho thuật toán LDA

Kết quả cho thấy mô hình với k = 5 đạt giá trị Score cao nhất (0.4815), cho thấy mức độ phân cụm rõ ràng và ổn định nhất trong toàn bộ các cấu hình được khảo sát. Khi số chủ đề tăng lên, giá trị Score giảm dần, phản ánh xu hướng các chủ đề bắt đầu chồng lấn và ranh giới giữa các cụm trở nên kém rõ ràng hơn.

Bên cạnh đó, tại k = 5, chỉ số Compactness đạt giá trị thấp nhất (0.0920), cho thấy các văn bản trong cùng một chủ đề có mức độ tương đồng cao và được gom cụm chặt chẽ. Khi số chủ đề tăng, compactness tăng dần, chứng tỏ các chủ đề trở nên phân mảnh hơn và tính nhất quán nội tại của từng chủ đề giảm.

Mặc dù chỉ số Separation có xu hướng tăng nhẹ khi k lớn hơn, phản ánh mức độ tách biệt giữa các chủ đề tăng lên, tuy nhiên sự cải thiện này không đủ để bù đắp cho sự suy giảm rõ rệt của Score và sự gia tăng của Compactness. Điều này cho thấy việc tăng số lượng chủ đề dẫn đến hiện tượng chia nhỏ quá mức, làm giảm chất lượng tổng thể của mô hình.

Tổng hợp các kết quả trên, K = 5 được lựa chọn là số lượng chủ đề tối ưu, do đạt được sự cân bằng tốt giữa độ tách biệt giữa các chủ đề (Separation) và độ chặt chẽ trong từng chủ đề (Compactness), đồng thời tối ưu hóa Silhouette Coefficient. Lựa chọn này không chỉ đảm bảo chất lượng phân cụm về mặt định lượng mà còn thuận lợi cho việc diễn giải ngữ nghĩa và phân tích nội dung các chủ đề trong các bước tiếp theo.

4.2.2. Kết quả phân cụm

Với số lượng chủ đề là 5, từ khóa nổi bật của từng chủ đề được liệt kê trong bảng sau:

Chủ đề	Từ khóa
0	'học', 'mua', 'kinh_nghiệm', 'sinh_viên', 'ngành', 'thực_tập', 'bé', 'xong', 'giúp', 'nha'
1	'lương', 'đóng', 'bệnh', 'tiền', 'bảo_hiểm', 'công_ty', 'bảo_hiểm_xã_hội', 'tr', 'nhân_viên', 'bây_giờ'
2	'công_việc', 'đầy_đủ', 'vị_trí', 'có_thể', 'làm_việc', 'công_ty', 'phù_hợp', 'thực_tập_sinh', 'thời_gian', 'thông_tin'
3	'hồ_sơ', 'chia_sẻ', 'làm_việc', 'bhxh', 'mẹ', 'vấn_đề', 'giúp', 'sản_phẩm', 'làm_sao', 'tự_nguyện'
4	'phỏng_vấn', 'công_ty', 'kinh_nghiệm', 'thất_nghiệp', 'nghỉ', 'anh_chị', 'lương', 'tuần', 'hr', 'thử'

Cụ thể,

- **Chủ đề 0** chủ yếu xoay quanh các nội dung liên quan đến quá trình học tập, sinh viên mới ra trường và giai đoạn thực tập. Các văn bản thuộc chủ đề này thường đề cập đến việc tích lũy kinh nghiệm, định hướng ngành nghề và những băn khoăn ban đầu khi bước vào môi trường làm việc.
- **Chủ đề 1** phản ánh các vấn đề về thu nhập, bảo hiểm và phúc lợi lao động. Nội dung các văn bản có xu hướng liên quan đến quyền lợi của người lao động, đặc biệt là các vấn đề về bảo hiểm xã hội và chế độ đãi ngộ.
- **Chủ đề 2** tập trung vào mô tả công việc và yêu cầu tuyển dụng. Các văn bản trong chủ đề này thường đề cập đến vị trí công việc, điều kiện làm việc, thời gian làm việc và mức độ phù hợp giữa ứng viên và doanh nghiệp.
- **Chủ đề 3** phản ánh các thắc mắc và trao đổi liên quan đến thủ tục, hồ sơ và các vấn đề hành chính – bảo hiểm. Nội dung mang tính hỏi đáp, chia sẻ kinh nghiệm hoặc xin lời khuyên trong quá trình làm việc và giải quyết các vấn đề phát sinh.

- **Chủ đề 4** chủ yếu đề cập đến quá trình tuyển dụng và phỏng vấn. Các văn bản thường xoay quanh trải nghiệm phỏng vấn, thử việc, nghỉ việc, cũng như những khó khăn trong giai đoạn tìm việc hoặc sau khi mất việc.

Kết quả diễn giải từ khóa và minh họa nội dung cho thấy các chủ đề thu được có ý nghĩa thực tiễn và phản ánh đúng các mối quan tâm chính của người dùng, bao gồm học tập – thực tập, quyền lợi lao động, mô tả công việc và quá trình tuyển dụng. Điều này cho thấy mô hình không chỉ đạt hiệu quả về mặt định lượng mà còn đảm bảo khả năng diễn giải ngữ nghĩa.

Tuy nhiên, mô hình vẫn tồn tại một số hạn chế: LDA chưa khai thác được đầy đủ ngữ cảnh ngữ nghĩa sâu của văn bản. Bên cạnh đó, sự không đồng đều về độ dài và phong cách viết của các bài đăng mạng xã hội cũng ảnh hưởng đến độ sắc nét của các chủ đề.

4.3. Mô hình NMF

4.3.1. Chọn số cụm phù hợp

Để có thể quyết định chính xác số cụm (số chủ đề), nhóm thực hiện chạy thuật toán NMF cho từng mốc siêu tham số từ 5 đến 30. Quan sát biểu đồ đường bên dưới, nhóm quyết định chọn số cụm là 5.

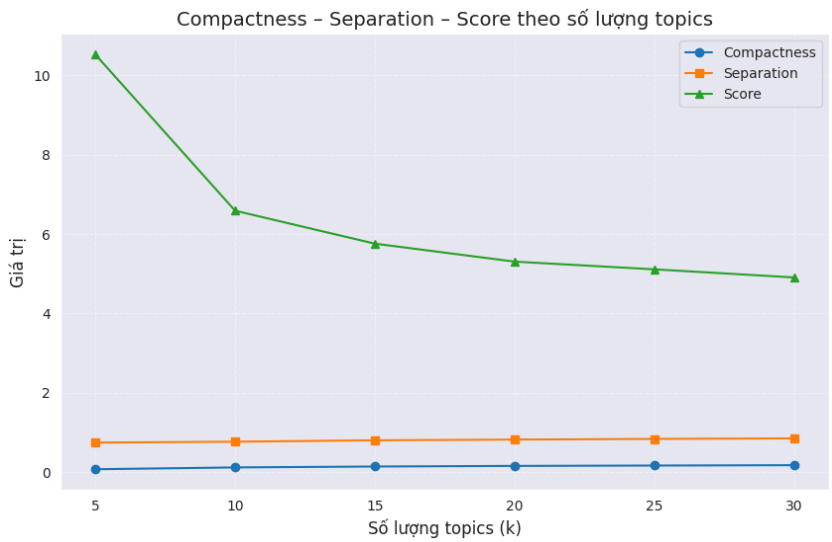

Hình 4.5. Kết quả so sánh để lựa chọn số chủ đề cho thuật toán NMF

4.3.2. Kết quả phân cụm

Sau khi huấn luyện mô hình, nhóm thu được ma trận trọng số:

- **H** – ma trận topic–word

mỗi topic được biểu diễn bởi các từ có trọng số cao trong cột tương ứng

- **W** – ma trận document–topic

mỗi văn bản được gán vào topic có trọng số lớn nhất

Chủ đề	**Từ khoá**
0	nhân_viên, công_ty, quản_lý, nghỉ, làm_việc, bắt, tiền, gia_đình, chính_thức, cũ
1	công_việc, kinh_nghiệm, học, làm_việc, thời_gian, môi_trường, có_thể, sinh_viên, thực_tập, thực_tập_sinh
2	lương, tr, lương tr, lương lương, ca, hạn, thưởng, lương hạn, trừ, thử
3	đóng, bảo_hiểm, công_ty, bệnh, bhxh, đóng bảo_hiểm, xã_hội, bảo_hiểm xã_hội, công_ty đóng, đóng bhxh
4	phỏng_vấn, hồ_sơ, câu, hr, trả_lời, gửi, tuyển_dụng, công_ty, mời, gọi

Thoạt nhìn dựa vào cảm quan, các chủ đề được phân ra khá rõ ràng và có ý nghĩa tách biệt cho từng chủ đề ví dụ như lương, thưởng đi cùng nhau hoặc đóng, bảo hiểm, xã hội, bảo hiểm xã hội, v.v.

Để chứng minh cho sự vững chắc về mặt ngữ nghĩa của mô hình NMF, nhóm tiến hành kiểm tra chỉ số Compactness và Separation giữa các chủ đề cũng như sinh caption cho từng chủ đề.

4.3.3. Sinh caption cho mỗi chủ đề

```
Topic 1: nhân_viên | công_ty | quản_lý | nghỉ | làm_việc |
Topic 2: công_việc | kinh_nghiệm | học | làm_việc | thời_gian |
Topic 3: lương | tr | lương tr | lương lương | ca |
Topic 4: đóng | bảo_hiểm | công_ty | bệnh | bhxh |
Topic 5: phỏng_vấn | hồ_sơ | câu | hr | trả_lời |
```

Khi so sánh với các kết quả sinh caption của 2 thuật toán LSA và LDA trên thì hàm sinh caption hoạt động với thuật toán NMF khá tương đồng, đặc biệt khá giống với thuật toán LSA. Đặc biệt ở Topic 4 và 5, hàm sinh caption dựa vào kết quả 2 thuật toán LSA và NMF đều cho ra các từ có cùng chủ đề (Topic 4: Chế độ Bảo hiểm xã hội và Topic 5: Thông báo và phản hồi phỏng vấn). Đó là do 2 thuật toán LSA và NMF có

sự giống nhau về ý tưởng nên cho ra kết quả khá giống. Kết luận: các nhãn chủ đề đưa ra khớp với thực tế và có cơ sở dữ liệu xác thực.

4.4. Mô hình BERTopic

4.4.1. Chọn số cụm phù hợp

Ban đầu với các cài đặt đơn giản nhất để đảm bảo thuật toán bắt được các đặc điểm và cấu trúc tự nhiên của dữ liệu, nhóm thực hiện cài đặt đơn giản các tham số của BERTopic như sau:

```
vectorizer_model = CountVectorizer(ngram_range=(1,3), stop_words=None)
topic_model = BERTopic(
    language="multilingual",
    vectorizer_model=vectorizer_model,
    min_topic_size=10,
    verbose=True
)
```

Kết quả phân ra 37 cụm (bao gồm cả cụm -1 - được định nghĩa là cụm rác của mô hình) với Compactness: 0.1393 và Separation: 0.2868 . Với số lượng trên 3000 bài viết nhưng Topic -1 chiếm đến 1489 bài cho thấy dữ liệu có độ phân tán cao và tính chất không đồng nhất (heterogeneous).

Điều này hoàn toàn hợp lý với đặc thù dữ liệu thu thập từ mạng xã hội/review, vốn chứa nhiều văn bản ngắn, thiếu ngữ cảnh hoặc các nội dung quá riêng biệt không đủ để tạo thành xu hướng (pattern). Về mặt thuật toán, BERTopic sử dụng HDBSCAN – một phương pháp phân cụm dựa trên mật độ (density-based). Khác với các thuật toán truyền thống buộc mọi điểm dữ liệu phải thuộc về một nhóm, HDBSCAN chủ động gán nhãn -1 cho các điểm dữ liệu nằm trong vùng mật độ thấp (low-density regions). Cơ chế này chấp nhận hy sinh số lượng dữ liệu bao phủ để **đảm bảo độ tinh khiết và liên kết chặt chẽ** (high coherence) cho các chủ đề chính được hình thành.

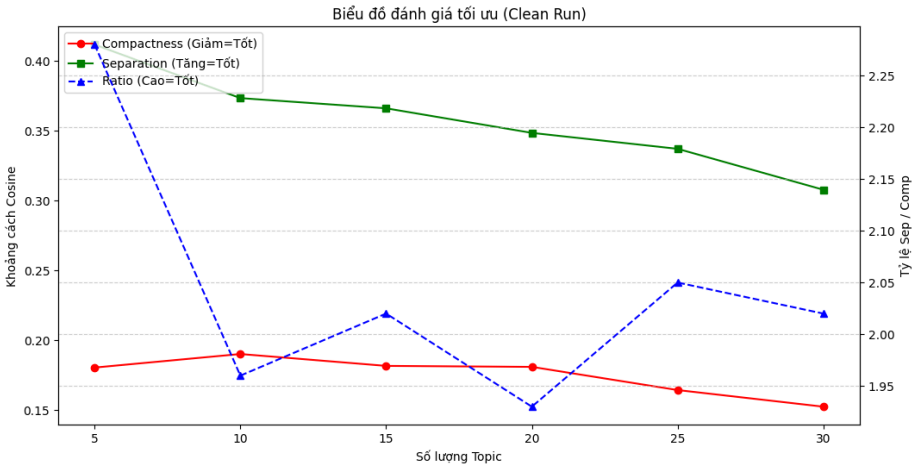

Hình 4.6. Biểu đồ đánh giá tối ưu

Tiếp theo nhóm quyết định, điều chỉnh số cụm tối ưu dựa trên 2 chỉ số Compactness và Separation. Tương tự với các thuật toán khác với Score cao nhất ở 5 cụm (đường màu xanh dương). Ta chọn giảm số topic về 5 để đảm bảo hiệu suất của thuật toán, hai chỉ số Compactness và Separation lần lượt là 0.1803 và 0.4115 phản ánh mức độ phân cụm trung bình trong thực tế bài toán.

4.4.2. Kết quả phân cụm

- Compactness (Độ nén) = 0.1803: Giá trị này ở mức thấp, cho thấy các văn bản trong cùng một cụm có sự gắn kết nội tại rất cao (high internal cohesion). Các điểm dữ liệu nằm gần centroid (tâm cụm), chứng tỏ các bài viết trong cùng một chủ đề có nội dung và từ vựng rất tương đồng nhau.
- Separation (Độ tách biệt) = 0.4115: Giá trị này ở mức trung bình khá. Điều này phản ánh rằng các cụm chủ đề có sự phân tách tương đối rõ ràng trong không gian vector. Tuy nhiên, việc chưa đạt mức rất cao (> 0.5 hoặc 0.6) là điều dễ hiểu đối với dữ liệu review/mạng xã hội, nơi các từ khóa chung như “công ty", "nhân viên", "lương" thường xuất hiện xuyên suốt ở nhiều chủ đề khác nhau, tạo ra một số vùng giao thoa nhất định.

Topic	Count	Name	Representation	Representative_Docs
-1	1489	-1_công_ty_nhân_viên_lương_công_việc	[công_ty, nhân_viên, lương, công_việc, làm_việ...	[công_ty gia_đình tổng_giám_đốc phó_giám_đốc q...
0	1517	0_lương_công_ty_nhân_viên_công_việc	[lương, công_ty, nhân_viên, công_việc, làm_việ...	[mẹ nợ lương nợ bảo_hiểm nợ tiền đầu_tư tư thằ...
1	31	1_facebook_video_tiktok_youtube	[facebook, video, tiktok, youtube, tập, sir, m...	[podcast hạt_giống tương_lai xanh tập tích_hợp...
2	21	2_lương_chậm_nhân_sự_nhân_viên	[lương, chậm, nhân_sự, nhân_viên, chậm lương, ...	[lập danh_mục nhân_sự tự_ý lương tất_cả nhân_v...
3	16	3_laptop_văn_phòng_mua_công_ty	[laptop, văn_phòng, mua, công_ty, sử_dụng, dân...	[tình_hình anni mua ny nam quà liên_quan công_...
4	11	4_boss_nhiệm_vụ_manager_nói_chuyện	[boss, nhiệm_vụ, manager, nói_chuyện, nhân_viê...	[lời_nói thân_thương boss yêu trình_độ bây_giờ...

Về Topic rác (-1): Việc Topic -1 và Topic 0 có từ khóa đại diện khá giống nhau (công ty, nhân viên) cho thấy ranh giới giữa "bài viết chung chung hợp lệ" (Topic 0) và "bài viết nhiễu" (Topic -1) là khá mong manh. Tuy nhiên, việc giữ lại Topic -1 lớn (1489 bài) đã giúp bảo vệ độ tinh khiết cao cho các Topic ngách (1, 2, 3, 4).

Hình 4.7. Topic -1 của mô hình BERTopic

Topic 0 chứa tới 1517 bài viết (xấp xỉ lượng bài của Topic rác -1).Từ khóa "lương, công ty, nhân viên, công việc" cho thấy đây là chủ đề "Phàn nàn chung" (General Complaints). Đây là xu hướng chủ đạo của bộ dữ liệu. Đa số người dùng lên tiếng để nói về các vấn đề tổng quan liên quan đến chế độ đãi ngộ (lương, bảo hiểm,...) và môi trường làm việc. Vì nội dung quá phổ biến và bao trùm, thuật toán đã gom chúng thành một "Siêu chủ đề" (Super-cluster).

Hình 4.8. Topic 0 của mô hình BERTopic

Mặc dù Topic 0 chiếm đa số, mô hình vẫn rất nhạy bén khi tách được các chủ đề nhỏ nhưng có ngữ nghĩa cực kỳ đặc thù (Niche topics):

Topic 1 (31 bài): Chủ đề về Truyền thông/Mạng xã hội (Keywords: facebook, video, tiktok, youtube). Đây là nhóm bài viết bàn về marketing hoặc kênh truyền thông, tách biệt hoàn toàn với nhóm phàn nàn về lương.

Hình 4.9. Topic 1 của mô hình BERTopic

Topic 3 (16 bài): Chủ đề về Cơ sở vật chất/Thiết bị (Keywords: laptop, văn phòng, mua). Việc tách được cụm này cho thấy Compactness hoạt động rất tốt, gom đúng những bài phàn nàn cụ thể về máy móc vào một chỗ.

Hình 4.10. Topic 3 của mô hình BERTopic

Topic 2 (21 bài) & Topic 4 (11 bài): Đây là các biến thể sâu hơn của vấn đề nhân sự (Topic 2 nhấn mạnh việc "nợ lương/lương chậm", Topic 4 nhấn mạnh về "sếp/quản lý").

Hình 4.11. Topic 2 & 4 của mô hình BERTopic

CHƯƠNG 5: ĐÁNH GIÁ VÀ SO SÁNH

5.1. So sánh các mô hình truyền thống - LDA, LSA, NMF

Trong nghiên cứu này, nhóm tiến hành thử nghiệm ba mô hình topic modelling truyền thống phổ biến gồm Latent Dirichlet Allocation (LDA), Latent Semantic Analysis (LSA) và Non-negative Matrix Factorization (NMF). Ba mô hình đều được huấn luyện trên cùng một tập dữ liệu và được thiết lập với cùng số lượng chủ đề k=5 nhằm đảm bảo tính công bằng trong quá trình so sánh. Mục tiêu của thí nghiệm là đánh giá hiệu năng của các mô hình truyền thống, từ đó lựa chọn mô hình phù hợp nhất để làm đối chứng khi so sánh với mô hình hiện đại dựa trên embedding (BERTopic) ở các phần tiếp theo.

5.1.1. Đánh giá dựa trên Chỉ số Định lượng

Hiệu năng của các mô hình được đánh giá thông qua hai chỉ số định lượng chính là Compactness (độ nén) và Separation (độ tách biệt). Chỉ số Compactness phản ánh mức độ tương đồng giữa các văn bản trong cùng một chủ đề, trong đó giá trị càng nhỏ cho thấy các văn bản trong cụm càng đồng nhất. Ngược lại, chỉ số Separation đo lường mức độ phân biệt giữa các chủ đề khác nhau, với giá trị càng lớn thể hiện ranh giới giữa các cụm càng rõ ràng. Ngoài ra, tỷ lệ giữa hai chỉ số này được sử dụng như một thước đo tổng hợp để so sánh hiệu năng tương đối giữa các mô hình.

Kết quả đánh giá được trình bày trong bảng sau.

Mô hình	Compactness	Separation	Score/Ratio	Nhận xét sơ bộ
LDA	0.0920	0.4642	0.4815	Độ tách biệt thấp nhất, các cụm dễ bị dính vào nhau.
LSA	0.0934	0.6903	7.3907	Độ tách biệt tốt nhưng độ nén kém nhất trong 3 mô hình.
NMF	0.0705	0.7423	10.5297	Tốt nhất cả hai chỉ số. Cụm gọn và tách biệt rõ ràng nhất.

Xét về khả năng tách biệt giữa các chủ đề, mô hình NMF đạt giá trị Separation cao nhất (0.7423), cho thấy các chủ đề được sinh ra có ranh giới rõ ràng và mức độ chồng lấn thấp. Trong khi đó, LDA có chỉ số Separation thấp nhất (0.4642), phản ánh đặc điểm cố hữu của mô hình khi cho phép mỗi tài liệu là hỗn hợp của nhiều chủ đề, dẫn đến sự giao thoa lớn giữa các cụm.

Về độ nén của các chủ đề, NMF tiếp tục thể hiện ưu thế với chỉ số Compactness thấp nhất (0.0705). Điều này cho thấy các văn bản thuộc cùng một chủ đề do NMF sinh ra có mức độ tương đồng cao, nội dung tập trung và nhất quán hơn so với LDA và LSA. Ngược lại, LSA có chỉ số Compactness cao nhất, cho thấy các cụm chủ đề có xu hướng phân tán hơn trong không gian biểu diễn.

Tổng hợp hai tiêu chí trên, NMF đạt tỷ lệ đánh giá tổng hợp cao nhất, vượt trội so với hai mô hình còn lại. Kết quả này cho thấy NMF là mô hình truyền thống phù hợp nhất trên tập dữ liệu nghiên cứu, đặc biệt trong bối cảnh cần các chủ đề có ranh giới rõ ràng và tính diễn giải cao. Do đó, trong các phân tích tiếp theo, NMF được lựa chọn làm mô hình truyền thống đại diện để so sánh với mô hình BERTopic.

5.1.2. Đánh giá dựa trên Phân phối và Ngữ nghĩa

Bên cạnh các chỉ số định lượng, việc phân tích nội dung từ khóa đại diện và phân bố số lượng bài viết theo từng chủ đề đóng vai trò quan trọng trong việc đánh giá tính khả thi của mô hình trong bối cảnh dữ liệu thực tế.

5.1.2.1. LSA

Mặc dù LSA đạt chỉ số Separation tương đối tốt, mô hình này lại bộc lộ hạn chế lớn về phân phối dữ liệu. Cụ thể, một chủ đề duy nhất (Topic 0) chiếm tới khoảng 89% tổng số bài viết, trong khi các chủ đề còn lại chỉ chứa số lượng rất nhỏ văn bản. Ngoài ra, các từ khóa quan trọng như “lương”, “nhân_viên”, “tr” xuất hiện lặp lại ở nhiều chủ đề khác nhau, làm giảm khả năng diễn giải và phân biệt ngữ nghĩa giữa các chủ đề.

Kết quả này cho thấy LSA có xu hướng gom phần lớn dữ liệu vào một chủ đề tổng quát, không phù hợp cho việc khám phá các chủ đề con có ý nghĩa trong tập dữ liệu mạng xã hội.

5.1.2.2. LDA

LDA cho phân phối số lượng bài viết khá cân bằng, tuy nhiên chất lượng từ khóa chưa cao:

- Topic 0: Chứa nhiều từ khóa nhiễu (noise words) không mang ý nghĩa chủ đề rõ ràng như: 'bé', 'xong', 'giúp', 'nha'.
- Topic 3: Có sự pha trộn ngữ nghĩa khó hiểu giữa "hồ sơ" (tuyển dụng) và "mẹ" (gia đình), "tự nguyện".
- Kết luận: LDA gặp khó khăn trong việc lọc nhiễu đối với dữ liệu văn bản ngắn (short text) như review/mạng xã hội.

5.1.2.3. NMF

NMF không chỉ có chỉ số tốt nhất mà còn đưa ra bộ từ khóa đại diện "sạch" và dễ gán nhãn nhất:

- Topic 2 (Lương thưởng): Các từ khóa chuyên biệt như "lương, thưởng, hạn, trừ, tr" mô tả chính xác vấn đề thu nhập.
- Topic 3 (Bảo hiểm): Gom nhóm hoàn hảo các từ khóa "đóng, bảo_hiểm, bhxh, xã_hội".
- Topic 4 (Tuyển dụng): Tách biệt rõ ràng quy trình tuyển dụng với "phỏng_vấn, hồ_sơ, hr, gọi, mời".
- Topic 0 (Quản trị/Môi trường): Phản ánh các vấn đề nội bộ như "quản_lý, nghỉ, bắt, gia_đình".

5.1.3. Kết luận lựa chọn mô hình

Từ những phân tích trên, nhóm nhận thấy:

1. LDA bị ảnh hưởng nhiều bởi nhiễu, từ khóa không sắc nét.
2. LSA bị thiên lệch dữ liệu quá lớn, không có giá trị phân tích thực tế.
3. NMF cân bằng tốt nhất giữa phân phối dữ liệu và ý nghĩa ngữ nghĩa.

Do đó, NMF được lựa chọn là mô hình đại diện cho nhóm thuật toán truyền thống. Trong phần tiếp theo, chúng tôi sẽ sử dụng kết quả của NMF để đối sánh trực tiếp với BERTopic nhằm làm rõ ưu thế của việc áp dụng mô hình ngôn ngữ lớn (BERT embeddings).

5.2. So sánh với mô hình Deep-Learning BERTopic

Sau khi lựa chọn NMF là đại diện xuất sắc nhất của nhóm mô hình truyền thống (với chỉ số Separation ấn tượng 0.7423), nhóm tiến hành đối sánh trực tiếp với BERTopic - mô hình đại diện cho phương pháp học sâu (Deep Learning).

5.2.1. Tổng quan các chỉ số so sánh

Bảng dưới đây tóm tắt sự chênh lệch hiệu năng giữa hai mô hình:

Tiêu chí	NMF	BERTopic

Cơ chế cốt lõi	Ma trận tần suất từ (TF-IDF)	Embedding ngữ cảnh (SBERT) + HDBSCAN
Compactness	0.0705 (Rất tốt)	0.1803 (Khá)
Separation	0.7423 (Rất tốt)	0.4115 (Trung bình)
Xử lý nhiễu	Không (Ép buộc gán nhãn)	Có (Tự động loại bỏ rác - Topic -1)
Số lượng Topic	Cố định K=5	5 Topic chính + 1 Topic rác (tự động)
Khả năng phát hiện	Các chủ đề lớn, đại trà	Các chủ đề ngách (Micro-topics)

5.2.2. So sánh về cơ chế và cách thức hoạt động

5.2.2.1. Chiến lược xử lý nhiễu

Mặc dù kết quả định lượng cho thấy NMF vượt trội so với BERTopic về các chỉ số Compactness và Separation, việc diễn giải các con số này cần được đặt trong bối cảnh đặc thù của dữ liệu văn bản mạng xã hội. Trên thực tế, ưu thế của NMF về mặt thống kê có thể tạo ra một "ảo ảnh hiệu năng" nếu không xem xét đến cơ chế xử lý nhiễu và triết lý mô hình hóa của từng thuật toán.

Trước hết, xét về chiến lược xử lý nhiễu, NMF hoạt động theo cơ chế cưỡng ép phân cụm. Do số lượng chủ đề k được xác định trước, thuật toán buộc phải gán toàn bộ văn bản vào đúng k cụm, bất kể nội dung của chúng có thực sự phù hợp hay không. Trong bối cảnh dữ liệu review và bài viết mạng xã hội vốn giàu nhiễu, nhiều câu ngắn, mơ hồ hoặc không mang nội dung chủ đề rõ ràng, NMF đã vô tình gom các bài viết này vào các chủ đề chính dựa trên sự lặp lại bề mặt của từ khóa. Điều này giúp các cụm đạt được độ tách biệt cao về mặt toán học, nhưng lại làm giảm độ "tinh khiết" ngữ nghĩa của từng chủ đề, khiến nội dung các cụm bị pha loãng bởi các văn bản không thực sự liên quan.

Ngược lại, BERTopic áp dụng một cách tiếp cận thực tế hơn đối với dữ liệu nhiễu. Thông qua việc sử dụng HDBSCAN trong không gian embedding ngữ nghĩa, mô hình cho phép tồn tại một nhóm ngoại lai (Topic -1) để chứa các văn bản không đủ tương đồng với bất kỳ cụm chủ đề nào. Trong thí nghiệm, có tới 1489 bài viết (gần

50% tập dữ liệu) được gán vào nhóm này. Mặc dù điều này làm giảm chỉ số Separation tổng thể — do Topic -1 phân bố rộng trong không gian vector — nhưng đổi lại, các chủ đề còn lại (Topic 0–4) đạt được mức độ nhất quán và rõ ràng rất cao về mặt ngữ nghĩa.

Từ góc độ bản chất mô hình, sự khác biệt này phản ánh hai triết lý tiếp cận hoàn toàn khác nhau. NMF ưu tiên tính đầy đủ về mặt phân cụm, chấp nhận gán nhãn cho mọi dữ liệu để tối ưu các chỉ số thống kê. Trong khi đó, BERTopic chấp nhận đánh đổi về mặt số lượng để bảo toàn độ chính xác và ý nghĩa của chủ đề. Có thể nói, BERTopic "thà loại bỏ dữ liệu không đáng tin cậy để giữ lại chủ đề sạch", trong khi NMF "chấp nhận gán nhãn sai để đảm bảo đủ số lượng".

Do đó, mặc dù NMF cho kết quả đẹp hơn về mặt chỉ số định lượng, BERTopic lại thể hiện ưu thế rõ rệt khi xét đến chất lượng ngữ nghĩa và tính khả dụng trong các bài toán phân tích dữ liệu văn bản thực tế, đặc biệt là dữ liệu mạng xã hội có mức độ nhiễu cao.

5.2.2.2 Không gian biểu diễn: Từ khóa và Ngữ cảnh

NMF hoạt động trên biểu diễn TF-IDF, trong đó văn bản được mô hình hóa dựa trên tần suất xuất hiện của từ. Do đó, các cách diễn đạt khác nhau nhưng có cùng ý nghĩa (ví dụ "lương thấp" và "thu nhập bèo bọt") vẫn có thể bị xem là xa nhau trong không gian đặc trưng, dẫn đến chỉ số Separation cao mang tính hình thức.

Ngược lại, BERTopic sử dụng embedding ngữ nghĩa từ Sentence-BERT, cho phép mô hình nắm bắt ngữ cảnh và ý nghĩa tiềm ẩn của văn bản. Những câu có nội dung tương đồng về mặt ngữ nghĩa sẽ được đặt gần nhau trong không gian vector, ngay cả khi chúng không chia sẻ từ vựng giống nhau. Vì vậy, mặc dù các chỉ số khoảng cách của BERTopic có thể không "đẹp" như các mô hình dựa trên TF-IDF, nhưng chúng phản ánh chính xác hơn cách con người hiểu và diễn giải ngôn ngữ.

5.2.3. So sánh khả năng phát hiện chủ đề (Topic Discovery)

Đây là điểm mà BERTopic thể hiện sự vượt trội hoàn toàn:

- NMF (Cái nhìn tổng quát): NMF chỉ tìm ra các chủ đề lớn như *Lương, Bảo hiểm, Tuyển dụng*. Đây là những thông tin bề mặt mà chúng ta có thể dễ dàng đoán trước.
- BERTopic (Cái nhìn chi tiết): Nhờ khả năng loại bỏ nhiễu, BERTopic đã "đãi cát tìm vàng" và phát hiện ra các Micro-topics (Chủ đề ngách) mà NMF bỏ qua:
    - *Topic 3 (Laptop/Cơ sở vật chất):* Chỉ với 16 bài viết nhưng vẫn được tách thành một cụm riêng. NMF đã nuốt chửng nhóm này vào các nhóm lớn hơn vì số lượng quá nhỏ.

- *Topic 1 (Social Media - TikTok/Youtube):* Tách biệt hoàn toàn mảng truyền thông khỏi mảng lương thưởng.

5.2.4. Kết luận

Mặc dù NMF cho ra các chỉ số định lượng ấn tượng hơn, nhưng đó là kết quả của việc đơn giản hóa quá mức và cưỡng ép dữ liệu.

Ngược lại, BERTopic chứng minh là mô hình phù hợp hơn cho bài toán phân tích review nhân sự này vì:

1. Tính trung thực: Dám loại bỏ 50% dữ liệu rác để bảo vệ độ chính xác của các phân tích còn lại.
2. Độ sâu: Phát hiện được các vấn đề tiềm ẩn (cơ sở vật chất, kênh truyền thông) thay vì chỉ lặp lại các vấn đề bề nổi.
3. Khả năng hiểu ngữ nghĩa: Xử lý tốt văn phong đa dạng, tiếng lóng, từ đồng nghĩa của người dùng mạng xã hội mà các mô hình đếm từ (Bag-of-words) như NMF không làm được.

CHƯƠNG 6: KẾT LUẬN

6.1. Các kết quả đạt được

Nhóm đã xây dựng thành công hệ thống thu thập dữ liệu tự động từ các nền tảng mạng xã hội như Threads và Reddit, tập trung vào các bài viết và bình luận liên quan đến thị trường lao động Việt Nam. Quá trình crawl được thiết kế với cơ chế tự động cuộn trang và loại bỏ nội dung trùng lặp, giúp đảm bảo tính đa dạng và nhất quán của dữ liệu. Việc chủ động thu thập dữ liệu thay vì sử dụng các bộ dữ liệu có sẵn giúp tập dữ liệu mang tính thời sự cao, phản ánh sát thực bối cảnh và mối quan tâm của người lao động trong giai đoạn nghiên cứu.

Bên cạnh đó, nhóm đã xây dựng một pipeline tiền xử lý chuyên biệt cho văn bản tiếng Việt nhằm nâng cao chất lượng dữ liệu đầu vào. Pipeline này bao gồm việc loại bỏ nội dung rác, spam và quảng cáo; chuẩn hóa teencode, từ viết tắt; loại bỏ email, liên kết và ký hiệu không mang ý nghĩa ngữ nghĩa; xử lý hiện tượng xen lẫn tiếng Anh trong văn bản tiếng Việt; tách từ bằng công cụ tokenizer tiếng Việt; loại bỏ stopwords nâng cao và áp dụng N-grams (bigram, trigram). Cuối cùng, dữ liệu được chuẩn hóa dưới dạng TF-IDF để phục vụ cho các mô hình truyền thống. Các bước này giúp giảm nhiễu đáng kể và tạo điều kiện để các mô hình topic modelling trích xuất chủ đề rõ ràng và nhất quán hơn.

Nhóm đã tiến hành thử nghiệm và đánh giá bốn mô hình phân cụm chủ đề phổ biến gồm LDA, LSA, NMF (nhóm mô hình truyền thống) và BERTopic (nhóm mô hình học sâu). Quá trình lựa chọn mô hình được thực hiện theo hai giai đoạn.

- Ở giai đoạn thứ nhất, NMF được xác định là mô hình truyền thống hiệu quả nhất nhờ đạt chỉ số Separation cao nhất (0.7423) và tạo ra các bộ từ khóa đại diện rõ nghĩa, khắc phục được tình trạng nhiễu của LDA và sự mất cân bằng nghiêm trọng của LSA.
- Ở giai đoạn thứ hai, nhóm tiến hành đối sánh trực tiếp giữa NMF và BERTopic. Mặc dù NMF có lợi thế về các chỉ số định lượng, BERTopic được lựa chọn làm mô hình cuối cùng do thể hiện khả năng hiểu ngữ nghĩa vượt trội thông qua cơ chế embedding. BERTopic cho phép phát hiện các chủ đề ngách (micro-topics) và xử lý dữ liệu mạng xã hội hỗn loạn một cách thực tế hơn thông qua việc gán nhãn Topic -1 cho các bài viết nhiễu, từ đó đảm bảo độ tinh khiết cao cho các chủ đề chính phục vụ phân tích.

6.2. Hạn chế

Mặc dù đạt được những kết quả tích cực, nghiên cứu vẫn tồn tại một số hạn chế.

Thứ nhất, bộ dữ liệu có sự mất cân bằng lớn giữa các chủ đề, trong đó nhóm chủ đề liên quan đến lương thưởng và chế độ chiếm tỷ trọng áp đảo. Điều này khiến mô hình có xu hướng gom các vấn đề nhỏ vào chủ đề lớn, làm giảm mức độ chi tiết của một số khía cạnh quản trị khác.

Thứ hai, dữ liệu do người dùng tạo ra chứa nhiều tiếng lóng, từ viết tắt, lỗi chính tả và teencode đặc thù tiếng Việt, gây khó khăn cho quá trình tiền xử lý và vector hóa, từ đó ảnh hưởng nhất định đến độ chính xác trong việc biểu diễn ngữ nghĩa.

Thứ ba, cơ chế HDBSCAN trong BERTopic đã gán khoảng 50% dữ liệu vào Topic -1. Mặc dù điều này giúp các chủ đề chính trở nên rõ ràng và nhất quán hơn, nhưng đồng thời cũng dẫn đến việc một lượng lớn thông tin có thể chứa các tín hiệu yếu hoặc các vấn đề mới phát sinh không được khai thác sâu.

Cuối cùng, hiệu quả của BERTopic phụ thuộc nhiều vào mô hình ngôn ngữ huấn luyện sẵn dùng để tạo embedding. Trong trường hợp mô hình nền chưa được tối ưu tốt cho ngữ cảnh tiếng Việt và lĩnh vực nhân sự, khả năng nắm bắt ngữ nghĩa chuyên sâu của mô hình vẫn còn bị giới hạn.

TÀI LIỆU THAM KHẢO

Albanese, N. C. (2022, September 19). *Topic Modeling with LSA, pLSA, LDA, NMF, BERTopic, Top2Vec: a Comparison | Towards Data Science*. Towards Data Science. https://towardsdatascience.com/topic-modeling-with-lsa-plsa-lda-nmf-bertopic-top2vec-a-comparison-5e6ce4b1e4a5/#78f7

Barbieri, N., Manco, G., Ritacco, E., Carnuccio, M., & Bevacqua, A. (2013). Probabilistic topic models for sequence data. *Machine Learning*, *93*(1), 5–29. https://doi.org/10.1007/s10994-013-5391-2

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of Machine Learning Research*, *3*, 993–1022. https://doi.org/10.5555/944919.944937

Deerwester, S., Dumais, S., Furnas, G., Landauer, T., & Harshman, R. (n.d.). *Indexing by Latent Semantic Analysis*. Retrieved April 18, 2019, from http://lsa.colorado.edu/papers/JASIS.lsi.90.pdf

Gong, D. (2025, May 8). *A Practical Guide to BERTopic for Transformer-Based Topic Modeling | Towards Data Science*. Towards Data Science. https://towardsdatascience.com/a-practical-guide-to-bertopic-for-transformer-based-topic-modeling/

Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *ArXiv:2203.05794 [Cs]*. https://doi.org/10.48550/arXiv.2203.05794

PHỤ LỤC

1. Mã nguồn dự án

Mã nguồn dự án được nhóm lưu trữ tại link GitHub sau:

https://github.com/wittyelephant53/NLP-TOPIC-MODELING-VIETNAMESE-JOB-INDUSTRY.git

Cụ thể các file trong github:

- EDA, Preprocess
- 3 models LDA, LSA, NMF
- Model BERT

2. Phân công công việc

Tên thành viên	Nhiệm vụ	% Đóng góp
Huỳnh Thụy Mai Nguyên	Tiền xử lý dữ liệu (dịch tiếng anh, stopwords, hashtag, link, mention, tokenize) EDA Thực hiện mô hình chạy NMF (Code & Báo cáo)	100%
Dương Phương Anh	Crawl dữ liệu từ Threads Thực hiện báo cáo lý thuyết Thực hiện chạy mô hình LSA (Code & Báo cáo)	100%
Nguyễn Đỗ Nhật Minh	Crawl dữ liệu từ Facebook Tiền xử lý dữ liệu (bỏ các văn bản spam) Thực hiện mô hình chạy BERTopic (Code & Báo cáo)	100%
Nguyễn Lợi Thanh Dũng	Crawl dữ liệu từ 1900.com.vn Thực hiện báo cáo lý thuyết Thực hiện chạy mô hình LDA (Code & Báo cáo)	100%